

Deloitte M&A AI Role & Agent Evaluation Framework

1. KI-FUNKTIONALITÄTEN, ARCHITEKTUR & TECHNOLOGIEN

Core Generative AI & LLMs

Entwicklung & Deployment von Generative-AI-Tools & agentischen Systemen auf Basis von Claude, Gemini, GPT-4o sowie Open-Source (Llama). Integration via Structured Outputs (JSON/Pydantic).

Prompt Engineering & Architecture

Systematisches Few-Shot Design, Instruction Tuning, Metaprompting und dynamische Kontext-Strukturierung für komplexe M&A-Anwendungsfälle.

Agentische Entwurfsmuster

Einsatz von ReAct, Planning-Agents und Multi-Agenten-Systemen zur Zerlegung komplexer M&A-Aufgaben mit automatisiertem Tool-Calling / Function-Calling.

Retrieval-Augmented Generation (RAG)

Verarbeitung unstrukturierter Deal-Datenräume (Due Diligence, Bilanzen, Verträge) via Semantic Search, Hybrid Search und fortschrittlichen Reranking-Strategien.

2. VERHALTENSREIHENFOLGE (AI ENGINEERING LIFECYCLE)

Der Entwicklungsprozess folgt einem iterativen, datengetriebenen End-to-End Workflow:

PHASE 1

Scoping

Übersetzung von M&A-Problemen in testbare Use Cases & Erfolgsmetriken.

PHASE 2

Engineering

Entwurf von Systemprompts, Few-Shots, Tool-Calling & RAG-Pipelines.

PHASE 3

Qualification

Strikte Evaluation, Benchmark-Tests & Error Budgeting.

PHASE 4

Deployment

Integration in Live-Mandate, Latenz- & Kostenoptimierung.

PHASE 5

Scaling

Dokumentation, Reusability & Knowledge Transfer.

3. KONKRETE JOB-SPEZIFIKATIONEN & ANFORDERUNGEN

- **M&A-Lernbereitschaft (Domain Integration):** Schneller Aufbau von Arbeitswissen in Post-Merger Integration (PMI), Carve-outs, Synergie-Tracking, PMO-Workflows und Day-1 Readiness.
- **Interdisziplinäre Schnittstelle:** Übersetzung komplexer KI-Architekturen in verständliche Business-Sprache für M&A-Partner, Mandanten und nicht-technische Stakeholder.
- **Technische Qualifikation:** Abschluss in Informatik, Data Science, Machine Learning oder quantitativen Fächern. Hands-on Erfahrung mit LLMs, Frameworks (LangChain, LlamaIndex, Instructor) und Prompting-Strategien. 1–2 Jahre Berufserfahrung im KI/ML-Umfeld von Vorteil.
- **Ownership & Governance:** End-to-End-Verantwortung für die Zuverlässigkeit, Sicherheit (Guardrails, Data Leakage Prevention) und Verlässlichkeit der Systeme.
- **Sprachen:** Fließendes Englisch zwingend; Deutsch oder Französisch von Vorteil.

4. DEEP-DIVE: FRAMEWORK ZUR AGENTEN-QUALIFIZIERUNG & EVALUATION

Um objektiv festzustellen, ob eine Systemanpassung (Prompt-Anpassung, RAG-Tuning, Modellwechsel) die Ausgabequalität verbessert oder verschlechtert, wird ein mehrdimensionales Evaluierungssystem eingesetzt.

A. Metriken-Katalog zur Output-Qualifikation

Kategorie	Metrik / Parameter	Messmethode / Definition	Zielzustand
RAG TRIAD	Context Relevance	Prüft, ob abgerufene Dokumenten-Chunks direkt relevant für die Aufgabenstellung sind.	Minimierung von Context-Noise
RAG TRIAD	Groundedness (Faithfulness)	Misst, ob jede Aussage im Output strikt durch die Quell-Dokumente belegt werden kann.	100% Halluzinationsfrei
RAG TRIAD	Answer Relevance	Misst, wie präzise die Antwort die tatsächliche Nutzerfrage adressiert.	Keine Abschweifung
INHALTSQUALITÄT	Vollständigkeit (Completeness)	Abgleich des Outputs gegen eine M&A-spezifische Pflicht-Checkliste.	Alle Kernpunkte enthalten
INHALTSQUALITÄT	Inhaltliche Korrektheit	Faktischer Abgleich aller Finanzdaten, Daten und Namen gegen Ground-Truth-Daten.	100% Akkuranz
AGENTEN-PERF.	Tool Execution Accuracy	Richtigkeit der gewählten Tools, API-Argumente und Abfrageparameter.	Fehlerfreie Aufrufe

B. Drei-Stufen Evaluation Pipeline

1. LLM-as-a-Judge Evaluation Ein übergeordnetes Modell (z. B. GPT-4o) bewertet den Output anhand strukturierter Rubriken. Führt automatische <i>Missing Information Audits</i> und <i>Fact-Checks</i> durch.	2. Syntaktische Asserter & Schemas Pydantic-Validierung erzwingt strikte Datenformate (JSON). Deterministische Regex-Tests prüfen das Vorhandensein kritischer M&A-Begriffe und Kennzahlen.
3. Domain Expert Human-in-the-Loop (M&A Subject Matter Expert Auditing) Erfahrene M&A-Practitioner führen blinde A/B-Tests durch, um Praxisnutzen, Tonalität und logische Konsistenz zu bewerten. Die Ergebnisse fließen kontinuierlich in eine <i>Golden Dataset Benchmark-Sammlung</i> ein.	

C. Qualifizierungsprotokoll & Produktions-Freigabe

Ein neues Release gilt ausschließlich dann als **qualifiziert für den Produktions-Einsatz**, wenn folgende mathematische Bedingung erfüllt ist:

$$\text{Qualifikations-Status} = \text{PASSED, falls } (\text{Faithfulness} = 100\% \ \& \ \text{Completeness} \geq 95\% \ \& \ \text{Regressionsrate} = 0\%)$$
$$\text{FAILED, sonst}$$

- 100% Faithfulness:** Es dürfen keinerlei erfundene Daten oder Halluzinationen auftreten.
- ≥ 95% Completeness:** Nahezu vollständige Abdeckung aller in der Prüfmatrix definierten Informationspunkte.
- 0% Regression:** Kein einziger Testfall im Benchmark-Set darf im Vergleich zur vorherigen Version ein schlechteres Ergebnis liefern.